

LAB1

Grupo 4

2026-02-06

#Link del repositorio: https://github.com/G1LB3T0/R_Lab_1.git

```
movies<-read.csv("movies_2026.csv")
```

```
library(dplyr)
```

```
##
```

```
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
```

```
##
```

```
##      filter, lag
```

```
## The following objects are masked from 'package:base':
```

```
##
```

```
##      intersect, setdiff, setequal, union
```

```
library(ggplot2)
```

```
library(tidyr)
```

```
library(nortest)
```

```
movies <- movies %>%  
  mutate(across(  
    c(popularity, budget, revenue, genresAmount, productionCoAmount,  
      productionCountriesAmount, voteCount, actorsAmount, castWomenAmount,  
      castMenAmount, releaseYear, runtime, voteAvg, actorsPopularity),  
    ~ as.numeric(.))
```

```
## Warning: There was 1 warning in `mutate()`.
```

```
## i In argument: `across(...)`.
```

```
## Caused by warning:
```

```
## ! NAs introduced by coercion
```

Ejercicio 1 - Haga una exploración rápida de sus datos, para eso haga un resumen de su conjunto

```
#de datos.
```

```
# Dimensiones del DataSet
dim(movies)
```

```
## [1] 19883    28
```

Para este primer ejercicio, utilizamos la función `dim()` para conocer el tamaño exacto de nuestra base de datos. Como podemos observar en el resultado del código, el dataset tiene 19,883 filas por 28 columnas. Esto significa que contamos con información de 19,883 películas diferentes y, para cada una de ellas, tenemos 28 variables o características (como el presupuesto, el género, los ingresos, etc.) para analizar.

Ejercicio 2 - Diga el tipo de cada una de las variables (cualitativa ordinal o nominal, cuantitativa

#continua, cuantitativa discreta)

Clasificación de Variables

Variable	Tipo
id	Cualitativa Nominal
originalTitle	Cualitativa Nominal
originalLanguage	Cualitativa Nominal
title	Cualitativa Nominal
homePage	Cualitativa Nominal
video	Cualitativa Nominal
director	Cualitativa Nominal
genres	Cualitativa Nominal
productionCompany	Cualitativa Nominal
productionCompanyCountry	Cualitativa Nominal
productionCountry	Cualitativa Nominal
actors	Cualitativa Nominal
actorsCharacter	Cualitativa Nominal
genresAmount	Cuantitativa Discreta
productionCoAmount	Cuantitativa Discreta
productionCountriesAmount	Cuantitativa Discreta
voteCount	Cuantitativa Discreta
actorsAmount	Cuantitativa Discreta
castWomenAmount	Cuantitativa Discreta
castMenAmount	Cuantitativa Discreta
releaseYear	Cuantitativa Discreta
popularity	Cuantitativa Continua
budget	Cuantitativa Continua
revenue	Cuantitativa Continua
runtime	Cuantitativa Continua
voteAvg	Cuantitativa Continua
actorsPopularity	Cuantitativa Continua
releaseDate	Cuantitativa Continua

Separar variables cualitativas y cuantitativas

Lista de Variables Cualitativas (Nominales y Ordinales)

```
movies_cualitativas <- c("id", "originalTitle", "originalLanguage", "title", "homePage",  
  "video", "director", "genres", "productionCompany",  
  "productionCompanyCountry", "productionCountry",  
  "actors", "actorsCharacter", "releaseDate")  
  
movies_cuali <- movies[, movies_cualitativas]
```

Lista de Variables Cuantitativas (Discretas y Continuas)

```
movies_cuantitativas <- c("popularity", "budget", "revenue", "genresAmount",  
  "productionCoAmount", "productionCountriesAmount",  
  "voteCount", "actorsAmount", "castWomenAmount",  
  "castMenAmount", "releaseYear", "runtime",  
  "voteAvg", "actorsPopularity")  
  
movies_cuanti <- movies[, movies_cuantitativas]
```

Ejercicio 3 Investigue si las variables cuantitativas siguen una distribución normal y haga una

tabla de frecuencias de las variables cualitativas. Explique todos los resultados.

```
resultados_lillie <- data.frame(  
  Variable = character(),  
  P_value = numeric(),  
  Normalidad = character()  
)  
  
for (var in movies_cuantitativas) {  
  x <- na.omit(movies[[var]])  
  
  # Saltar variables no numéricas reales (como fechas)  
  if (!is.numeric(x)) next  
  
  test <- nortest::lillie.test(x)  
  
  resultados_lillie <- rbind(  
    resultados_lillie,  
    data.frame(  

```

```

    Variable = var,
    P_value = test$p.value,
    Normalidad = ifelse(test$p.value > 0.05, "Sí", "No")
  )
}

```

resultados_lillie


##	Variable	P_value	Normalidad
## 1	popularity	0	No
## 2	budget	0	No
## 3	revenue	0	No
## 4	genresAmount	0	No
## 5	productionCoAmount	0	No
## 6	productionCountriesAmount	0	No
## 7	voteCount	0	No
## 8	actorsAmount	0	No
## 9	castWomenAmount	0	No
## 10	castMenAmount	0	No
## 11	releaseYear	0	No
## 12	runtime	0	No
## 13	voteAvg	0	No
## 14	actorsPopularity	0	No

```

movies |>
  select(all_of(movies_cuantitativas)) |>
  pivot_longer(cols = everything(),
    names_to = "variable",
    values_to = "valor") |>
  filter(!is.na(valor)) |>
  ggplot(aes(x = valor)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  facet_wrap(~variable, scales = "free") +
  labs(title = "Histogramas de Variables Cuantitativas")


```

Histogramas de Variables Cuantitativas



```
movies |>
  select(all_of(movies_cuantitativas)) |>
  pivot_longer(cols = everything(),
               names_to = "variable",
               values_to = "valor") |>
  filter(!is.na(valor)) |>
  ggplot(aes(y = valor)) +
  geom_boxplot(fill = "tomato") +
  facet_wrap(~variable, scales = "free") +
  labs(title = "Diagramas de Bigotes de Variables Cuantitativas")
```

Diagramas de Bigotes de Variables Cuantitativas



```
# Idioma original
freq_idioma <- movies %>%
  count(originalLanguage, sort = TRUE) %>%
  head(10)

# Video promocional
freq_video <- movies %>%
  count(video, sort = TRUE) %>%
  head(10)

# Géneros
freq_generos <- movies %>%
  count(genres, sort = TRUE) %>%
  head(10)

# País de producción
freq_pais <- movies %>%
  count(productionCountry, sort = TRUE) %>%
  head(10)

# País de la productora
freq_pais_prod <- movies %>%
  count(productionCompanyCountry, sort = TRUE) %>%
  head(10)

# Directores (Top 10)
```

```

freq_director <- movies %>%
  count(director, sort = TRUE) %>%
  head(10)

# Productoras (Top 10)
freq_productora <- movies %>%
  count(productionCompany, sort = TRUE) %>%
  head(10)

# Imprimir resultados
freq_idioma

```

```

##      originalLanguage      n
## 1                en 11961
## 2                 es  1238
## 3                 fr  1094
## 4                 ja   868
## 5                 pt   628
## 6                 de   461
## 7                 zh   365
## 8                 ko   336
## 9                 it   302
## 10                nl   192

```

```
freq_video
```

```

##      video      n
## 1 FALSE 19313
## 2    NA   486
## 3  TRUE    84

```

```
freq_generos
```

```

##      genres      n
## 1              1965
## 2    Documentary 1847
## 3          Drama 1705
## 4        Comedy 1016
## 5        Horror  502
## 6    Animation  318
## 7    Drama|Romance 301
## 8    Horror|Thriller 282
## 9    Comedy|Drama  260
## 10    Comedy|Romance 250

```

```
freq_pais
```

```

##      productionCountry      n
## 1    United States of America 4968
## 2                                3874
## 3                                US  850

```

```
## 4                                Japan 613
## 5                                FR 428
## 6                                GB 357
## 7  United Kingdom|United States of America 339
## 8                                BR 327
## 9                                IN 315
## 10                               DE 307
```

freq_pais_prod

```
##      productionCompanyCountry      n
## 1                                8163
## 2                                US 1186
## 3                                US|US 833
## 4                        US|US|US 474
## 5                                |US 314
## 6                                | 299
## 7                                US| 292
## 8                                JP 283
## 9                                <NA> 247
## 10                       US|US|US|US 183
```

freq_director

```
##      director      n
## 1                                976
## 2  Steven Spielberg 29
## 3  Clint Eastwood 28
## 4  Ridley Scott 23
## 5  Kunihiro Yuyama 19
## 6  Martin Scorsese 19
## 7  Steven Soderbergh 19
## 8  Robert Zemeckis 18
## 9  Ron Howard 18
## 10 Woody Allen 17
```

freq_productora

```
##      productionCompany      n
## 1                                5656
## 2      Paramount 55
## 3  Universal Pictures 50
## 4  Warner Bros. Pictures 37
## 5      Toei Animation 36
## 6  DreamWorks Animation 33
## 7      The Asylum 33
## 8  Columbia Pictures 32
## 9      Marvel Studios 31
## 10 Walt Disney Pictures 31
```

Para las variables cualitativas, se construyeron tablas de frecuencia únicamente para aquellas variables que presentan categorías repetidas y relevantes para el análisis estadístico, como idioma original, género, país de

producción y presencia de video promocional. Variables como el id no fueron analizadas mediante tablas de frecuencia debido a que funcionan como identificadores.

Las tablas de frecuencia muestran una alta concentración en ciertos idiomas y países de producción, así como la dominancia de algunos géneros cinematográficos, lo que refleja patrones claros del mercado audiovisual.

Ejercicio 4 - Responder las siguientes preguntas:

Ejercicio 4.1 - ¿Cuáles son las 10 películas que contaron con más presupuesto?

```
# Crear una variable para el top 10
top_Ten_budget <- movies %>%
  # Seleccionar solo nombre y dinero (para no ver 28 columnas)
  select(originalTitle, budget) %>%
  # Ordenar descendente (de mayor a menor) por presupuesto
  arrange(desc(budget)) %>%
  # Solo los primeros 10
  head(10)

# Mostrar la tabla
top_Ten_budget
```

```
##               originalTitle    budget
## 1  Pirates of the Caribbean: On Stranger Tides 3.80e+08
## 2                Avengers: Age of Ultron 3.65e+08
## 3                Avengers: Endgame 3.56e+08
## 4                Avatar: Fire and Ash 3.50e+08
## 5  Pirates of the Caribbean: At World's End 3.00e+08
## 6                Justice League 3.00e+08
## 7                Avengers: Infinity War 3.00e+08
## 8                Superman Returns 2.70e+08
## 9                  Tangled 2.60e+08
## 10               The Lion King 2.60e+08
```

Al analizar las 10 películas con mayor presupuesto, observamos que el ranking es liderado por Pirates of the Caribbean: On Stranger Tides con una inversión aproximada de 380 millones de dólares. Se evidencia un dominio absoluto de grandes franquicias consolidadas, principalmente del Universo Cinematográfico de Marvel y producciones de Disney, lo que indica que la industria destina sus mayores recursos financieros a secuelas de géneros como ciencia ficción y fantasía, donde el uso intensivo de efectos visuales (CGI) y la contratación de elencos estelares elevan significativamente los costos de producción.

Ejercicio 4.2 - ¿Cuáles son las 10 películas que más ingresos tuvieron?

```
# Crear una variable para el top 10 de ingresos
top_revenue <- movies %>%
  # Ordenar por ingresos
  arrange(desc(revenue)) %>%
  # Seleccionar solo nombre y dinero (para no ver 28 columnas)
  select(originalTitle, revenue) %>%
  # Solo ver los primeros 10
  head(10)

# Mostrar la tabla
top_revenue
```

```
##           originalTitle    revenue
## 1             Avatar 2847246203
## 2   Avengers: Endgame 2797800564
## 3             Titanic 2187463944
## 4 Star Wars: The Force Awakens 2068223624
## 5   Avengers: Infinity War 2046239637
## 6       Zootopia 2 1744338246
## 7     Jurassic World 1671713208
## 8       The Lion King 1667635327
## 9 Spider-Man: No Way Home 1631853496
## 10      The Avengers 1518815515
```

Al examinar las 10 películas con mayores ingresos mundiales, Avatar se posiciona como la líder indiscutible con una recaudación superior a los 2.8 mil millones de dólares, seguida muy de cerca por Avengers: Endgame. Es interesante notar que, aunque el género de superhéroes y las franquicias establecidas dominan la lista (con múltiples entregas de Marvel y Star Wars), directores visionarios como James Cameron logran destacar con historias originales o de época (Avatar, Titanic). Además, al contrastar esta lista con la de presupuestos (Ejercicio 4.1), se evidencia que no siempre la película más cara es la más taquillera, aunque existe una clara tendencia de que las grandes superproducciones de efectos visuales son las que garantizan el éxito masivo en la taquilla global.

Ejercicio 4.3 - ¿Cuál es la película que más votos tuvo?

```
mas_votos <- movies %>%
  # Seleccionar también el promedio para ver si es buena
  select(originalTitle, voteCount, voteAvg) %>%
  # Ordenar por cantidad de votos
  arrange(desc(voteCount)) %>%
  # Solo ver la primera película
  head(1)

# Imprimir la película con más votos
mas_votos
```

```
##   originalTitle voteCount voteAvg
## 1      Inception    30788     8.4
```

La película que registra la mayor cantidad de votos en el conjunto de datos es “Inception”, acumulando un total de 30,788 evaluaciones por parte de los usuarios. Este alto nivel de participación, acompañado de una calificación promedio sobresaliente de 8.4, indica que la obra dirigida por Christopher Nolan no solo alcanzó una audiencia masiva, sino que logró un impacto cultural significativo que motivó a los espectadores a dejar su opinión, consolidándose como un referente del cine moderno tanto en popularidad como en calidad percibida.

Ejercicio 4.4 - ¿Cuál es la peor película de acuerdo a los votos de todos los usuarios?

```
peor_pelicula <- movies %>%  
  # Filtrar para quitar películas con 1 o 2 votos que ensucian la data  
  filter(voteCount > 20) %>%  
  # Seleccionar solo nombre y promedio de votos (para no ver 28 columnas)  
  select(originalTitle, voteAvg, voteCount) %>%  
  # Ordenamos de MENOR a MAYOR (ascendente)  
  arrange(voteAvg) %>%  
  # Solo ver la primera película  
  head(1)  
  
# Imprimir la tabla  
peor_pelicula
```

```
##   originalTitle voteAvg voteCount  
## 1 Almighty Thor      2.7         39
```

Al analizar las películas con menor calificación (aplicando un filtro de al menos 20 votos para asegurar representatividad estadística), la película “Almighty Thor” se posiciona como la peor evaluada del conjunto de datos. Con un promedio de calificación de 2.7 basado en 39 votos, esta producción refleja un rechazo contundente por parte de la audiencia. El uso del filtro fue crucial en este paso, ya que evitó que el resultado se viera sesgado por películas desconocidas o errores de captura con una única calificación de 0 o 1, permitiendo identificar una obra que realmente generó una experiencia negativa consensuada entre los espectadores.

Ejercicio 4.5 - ¿Cuántas películas se hicieron en cada año? ¿En qué año se hicieron más

películas? Haga un gráfico de barras

```
peliculas_anio <- movies %>%  
  filter(!is.na(releaseYear)) %>%  
  count(releaseYear, sort = TRUE)  
  
peliculas_anio
```


```
##   releaseYear    n  
## 1         2025 7351  
## 2         2026 2537
```

## 3	2021	814
## 4	2018	628
## 5	2017	617
## 6	2019	611
## 7	2016	557
## 8	2020	531
## 9	2015	450
## 10	2014	432
## 11	2013	412
## 12	2011	361
## 13	2009	342
## 14	2012	328
## 15	2010	307
## 16	2008	282
## 17	2006	272
## 18	2007	266
## 19	2005	245
## 20	2004	229
## 21	2003	199
## 22	2002	185
## 23	2001	176
## 24	2000	132
## 25	1999	97
## 26	1998	92
## 27	1997	84
## 28	1993	83
## 29	1995	79
## 30	1996	76
## 31	1994	65
## 32	1992	63
## 33	1988	59
## 34	1989	59
## 35	1987	53
## 36	1991	50
## 37	1986	48
## 38	1985	47
## 39	1990	47
## 40	1984	41
## 41	1982	35
## 42	1981	30
## 43	1983	28
## 44	1978	22
## 45	1977	21
## 46	1979	20
## 47	1980	20
## 48	1973	19
## 49	1976	18
## 50	1963	16
## 51	1967	16
## 52	1971	16
## 53	1974	16
## 54	1975	16
## 55	1957	15
## 56	1968	15

## 57	1953	13
## 58	1962	13
## 59	1966	13
## 60	1972	13
## 61	1959	12
## 62	1970	12
## 63	1954	11
## 64	1956	11
## 65	1969	11
## 66	1961	10
## 67	1964	10
## 68	1958	9
## 69	1960	9
## 70	1952	8
## 71	1965	8
## 72	1940	7
## 73	1948	7
## 74	1955	7
## 75	2022	7
## 76	1951	6
## 77	1931	4
## 78	1939	4
## 79	1941	4
## 80	1942	4
## 81	1944	4
## 82	1946	4
## 83	1947	4
## 84	1950	4
## 85	1949	3
## 86	1925	2
## 87	1927	2
## 88	1943	2
## 89	1902	1
## 90	1920	1
## 91	1921	1
## 92	1922	1
## 93	1926	1
## 94	1929	1
## 95	1930	1
## 96	1932	1
## 97	1933	1
## 98	1935	1
## 99	1936	1
## 100	1937	1
## 101	1938	1

```
ggplot(peliculas_anio, aes(x = factor(releaseYear), y = n)) +
  geom_col(fill = "steelblue") +
  labs(
    title = "Cantidad de películas por año",
    x = "Año de estreno",
    y = "Cantidad de películas"
  ) +
  theme(axis.text.x = element_text(angle = 90, vjust = 0.5))
```

Cantidad de películas por año



El gráfico muestra la cantidad de películas producidas por año. El año que más películas ha producido fue el 2025 con una cantidad inmensa de películas.

Ejercicio 4.6 - ¿Cuál es el género principal de las 20 películas más recientes? ¿Cuál es el género

principal que predomina en el conjunto de datos? Represéntelo usando un gráfico. ¿A qué género principal pertenecen las películas más largas?

```
# --- Ejercicio 4.6: Géneros Principales y Películas Largas (CORREGIDO) ---

# 1. Limpieza: Extraer género y eliminar los que queden vacíos
movies <- movies %>%
  mutate(mainGenre = sapply(strsplit(as.character(genres), "\\|"), "[", 1))

# 2. Géneros en las 20 películas más recientes
recent_genres <- movies %>%
  filter(!is.na(mainGenre)) %>%
  arrange(desc(releaseDate)) %>%
  head(20) %>%
  count(mainGenre, sort = TRUE)

print("Géneros en las 20 películas más recientes:")
```

```
## [1] "Géneros en las 20 películas más recientes:"
```

```
print(recent_genres)
```

```
##      mainGenre n
## 1      Drama 6
## 2      Comedy 4
## 3      Animation 3
## 4      Thriller 3
## 5      Action 1
## 6 Documentary 1
## 7      Romance 1
## 8         War 1
```

```
# 3. Gráfico del género predominante
```

```
movies %>%
```

```
  filter(!is.na(mainGenre)) %>%
```

```
  count(mainGenre) %>%
```


```
  mutate(mainGenre = reorder(mainGenre, n)) %>%
```

```
  ggplot(aes(x = mainGenre, y = n)) +
```

```
  geom_col(fill = "steelblue") +
```

```
  coord_flip() +
```

```
  labs(title = "Cantidad de Películas por Género", x = "Género", y = "Cantidad")
```



```
# 4. Películas más largas (Usando el título en inglés para evitar símbolos raros)
```

```
longest_movies <- movies %>%
```

```

filter(!is.na(runtime), !is.na(mainGenre)) %>% # Quitamos pelis sin duración o género
arrange(desc(runtime)) %>%
select(title, mainGenre, runtime) %>%
head(10)

print("Top 10 películas más largas:")

```

```
## [1] "Top 10 películas más largas:"
```

```
print(longest_movies)
```

```
##                               title    mainGenre
## 1      How Ponyo was Born ~Hayao Miyazaki's Thought Process~ Documentary
## 2                Before the End              Action
## 3 Crystal Lake Memories: The Complete History of Friday the 13th Documentary
## 4      In Search of Darkness: 1995-1999 Documentary
## 5                Napoleon                  Drama
## 6      White Gardenia: The King James Bible          Horror
## 7                1900                  Drama
## 8      The Idolmaster Gakuen: Story of Re;IRIS      Animation
## 9                Indie Beat                  Music
## 10      2025 Rock & Roll Hall of Fame Induction Ceremony      Music
## runtime
## 1      750
## 2      675
## 3      400
## 4      384
## 5      333
## 6      330
## 7      317
## 8      284
## 9      261
## 10     261
```

Ejercicio 4.7 - ¿Las películas de qué genero principal obtuvieron mayores ganancias?


```

# Calculamos el ingreso promedio por género
# Importante: Filtramos revenue > 0 para quitar películas que no reportaron ganancias
movies %>%
  filter(!is.na(mainGenre), !is.na(revenue), revenue > 0) %>%
  group_by(mainGenre) %>%
  summarise(
    ingreso_promedio = mean(revenue, na.rm = TRUE)
  ) %>%
  arrange(desc(ingreso_promedio)) %>%
  # Gráfico ordenado
  ggplot(aes(x = reorder(mainGenre, ingreso_promedio), y = ingreso_promedio)) +
  geom_col(fill = "#2E8B57") +

```



```
coord_flip() +
scale_y_continuous(labels = scales::comma) + # Para que los números se vean bonitos (ej. 1,000,000)
labs(
  title = "Ingreso Promedio por Género Principal",
  subtitle = "Considerando solo películas con ganancias reportadas (>0)",
  x = "Género",
  y = "Ingreso Promedio ($)"
)
```




Ejercicio 4.8 - ¿La cantidad de actores influye en los ingresos de las películas? ¿se han hecho

películas con más actores en los últimos años?

```
movies %>%
  filter(!is.na(actorsAmount), !is.na(revenue)) %>%
  ggplot(aes(x = actorsAmount, y = revenue)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(
    title = "Relación entre cantidad de actores e ingresos",
    x = "Cantidad de actores",
```


```
y = "Ingresos"
)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```



```
movies %>%
  filter(!is.na(releaseYear), !is.na(actorsAmount)) %>%
  group_by(releaseYear) %>%
  summarise(promedio_actores = mean(actorsAmount, na.rm = TRUE)) %>%
  ggplot(aes(x = releaseYear, y = promedio_actores)) +
  geom_line(color = "darkgreen") +
  labs(
    title = "Promedio de actores por película a lo largo del tiempo",
    x = "Año",
    y = "Promedio de actores"
  )
```

Promedio de actores por película a lo largo del tiempo



No se observa una relación fuerte entre la cantidad de actores y los ingresos, aunque películas con elencos más grandes tienden a tener mayores ingresos en algunos casos.

Ejercicio 4.9 - ¿Es posible que la cantidad de hombres y mujeres en el reparto influya en la

popularidad y los ingresos de las películas?

```
# --- Ejercicio 4.9: ¿Influye la cantidad de hombres/mujeres en el éxito? ---

# 1. Calculamos la correlación matemática (0 = no hay relación, 1 = relación total)
# Usamos 'use="complete.obs"' para ignorar filas vacías
cor_hombres_rev <- cor(movies$castMenAmount, movies$revenue, use = "complete.obs")
cor_mujeres_rev <- cor(movies$castWomenAmount, movies$revenue, use = "complete.obs")
cor_hombres_pop <- cor(movies$castMenAmount, movies$popularity, use = "complete.obs")
cor_mujeres_pop <- cor(movies$castWomenAmount, movies$popularity, use = "complete.obs")

# Imprimimos los resultados en consola
print(paste("Correlación Cantidad Hombres vs Ingresos:", round(cor_hombres_rev, 3)))
```

```
## [1] "Correlación Cantidad Hombres vs Ingresos: -0.027"
```

```
print(paste("Correlación Cantidad Mujeres vs Ingresos:", round(cor_mujeres_rev, 3)))
```

```
## [1] "Correlación Cantidad Mujeres vs Ingresos: -0.017"
```

```
# 2. Gráficos Visuales
```

```
# Vamos a unir los datos para graficarlos juntos y comparar
```

```
# (Esto crea un gráfico dividido en 2 paneles: Hombres y Mujeres)
```

```
movies %>%
```

```
  select(castMenAmount, castWomenAmount, revenue) %>%
```

```
  pivot_longer(cols = c(castMenAmount, castWomenAmount),
```

```
               names_to = "Genero",
```

```
               values_to = "Cantidad") %>%
```

```
  filter(revenue > 0, Cantidad < 50) %>% # Filtramos casos extremos para ver mejor
```

```
  ggplot(aes(x = Cantidad, y = revenue, color = Genero)) +
```

```
  geom_point(alpha = 0.3) + # Puntos transparentes para ver la densidad
```

```
  geom_smooth(method = "lm", color = "black") + # Línea de tendencia
```

```
  facet_wrap(~Genero) + # Separa en dos gráficos
```

```
  scale_y_continuous(labels = scales::comma) +
```

```
  labs(
```

```
    title = "Impacto de la cantidad de actores/actrices en los Ingresos",
```


```
    x = "Cantidad de personas en el elenco",
```

```
    y = "Ingresos ($)"
```

```
)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

Impacto de la cantidad de actores/actrices en los Ingresos



Al analizar los gráficos de dispersión, observamos una nube de puntos bastante dispersa en ambos paneles (hombres y mujeres). Si bien las líneas de tendencia muestran una inclinación positiva muy leve (es decir, a mayor elenco, podría haber un poco más de ingresos), la relación es débil.

Podemos ver películas con elencos grandes (más de 30 personas) que tuvieron ingresos bajos, y películas con elencos pequeños que fueron éxitos millonarios.

Ejercicio 4.10 - ¿Quiénes son los directores que hicieron las 20 películas mejor calificadas?

```
# --- Ejercicio 4.10: Directores de las 20 películas mejor calificadas ---

# Seleccionamos las mejores películas
# 1. Filtramos voteCount > 100 para asegurar que sean calificaciones confiables
# 2. Ordenamos por promedio de votos (voteAvg) de mayor a menor
top_directors <- movies %>%
  filter(voteCount > 100) %>%
  arrange(desc(voteAvg)) %>%
  head(20) %>%
  select(director, title, voteAvg, voteCount) # Usamos 'title' para evitar símbolos raros

print("Top 20 películas mejor calificadas y sus directores:")
```

```
## [1] "Top 20 películas mejor calificadas y sus directores:"
```

```
print(top_directors)
```

```
##
## 1      Kim Nam-joon|Jeon Jung-kook|Kim Tae-hyung|Park Ji-min|Jung Ho-seok|Kim Seok-jin|Min Yoon
## 2
## 3
## 4      Carlos P\xe9rez Oso
## 5      Park Jun-
## 6      Taichi Ishida
## 7      Takahiro M
## 8      Amp W
## 9      Francis Ford Copp
## 10     Frank Darab
## 11     Aditya Chop
## 12 Beyonc\xe9|Mark Romanek|Jonas \xc5kerlund|Kahlil Joseph|Melina Matsoukas|Todd Tourso|Dikayl Rimmer
## 13     Kotaro Tam
## 14     Francis Ford Copp
## 15     Steven Spielb
## 16     Lee Joon-
## 17     Makoto Shin
## 18     Sebastian Jones|Ramez Sil
## 19     Alexandr Domogarov
## 20
##
##          title voteAvg voteCount
## 1  BTS World Tour: Love Yourself - Japan Edition      9.2      265
## 2          Break the Silence: The Movie                9.2      139
## 3          Bring the Soul: The Movie                    9.1      309
## 4  The Three Deaths of Marisela Escobedo              9.0      179
## 5          Burn the Stage: The Movie                    8.9      328
## 6          Violet Evergarden: The Movie                 8.8      182
## 7          Your Eyes Tell                              8.8      197
## 8          Green Snake                                  8.8      120
## 9          The Godfather                                8.7     15380
## 10         The Shawshank Redemption                     8.7     20598
## 11         Dilwale Dulhania Le Jayenge                  8.7     3372
## 12         Lemonade                                    8.7      132
## 13         Josee, the Tiger and the Fish                 8.7      162
## 14         The Godfather: Part II                       8.6     9266
## 15         Schindler's List                             8.6     12282
## 16         Hope                                          8.6      292
## 17         Your Name.                                   8.6     8274
## 18         Everybody's Everything                       8.6      211
## 19         A Dog Named Palma                           8.6      110
## 20         The Legend of Hei                            8.6      105
```

Ejercicio 4.11 - ¿Cómo se correlacionan los presupuestos con los ingresos? ¿Los altos

presupuestos significan altos ingresos? Haga los gráficos que necesite, histograma, diagrama de dispersión

```
# Correlacion numerica
correlacion <- cor(movies$budget, movies$revenue, use = "complete.obs")
print(paste("Coeficiente de correlación:", round(correlacion, 4)))
```

```
## [1] "Coeficiente de correlación: 0.7758"
```

```
# Diagrama de dispersión
grafico_dispersion <- ggplot(movies, aes(x = budget, y = revenue)) +
  # Color verde para los puntos
  geom_point(alpha = 0.5, color = "#2E8B57") +
  # Línea de tendencia roja
  geom_smooth(method = "lm", color = "red", se = FALSE) +
  labs(title = "¿Los altos presupuestos significan altos ingresos?",
       subtitle = paste("Correlación de Pearson:", round(correlacion, 2)),
       x = "Presupuesto (Budget)",
       y = "Ingresos (Revenue)") +
  theme_minimal()
```

```
# Histograma de presupuestos
hist_presupuesto <- ggplot(movies, aes(x = budget)) +
  geom_histogram(bins = 40, fill = "#4682B4", color = "white") +
  labs(title = "Distribución de los Presupuestos",
       x = "Presupuesto ($)",
       y = "Cantidad de Películas") +
  theme_minimal()
```


```
# Histograma de Ingresos
hist_ingresos <- ggplot(movies, aes(x = revenue)) +
  geom_histogram(bins = 40, fill = "#E9967A", color = "white") +
  labs(title = "Distribución de los Ingresos",
       x = "Ingresos ($)",
       y = "Cantidad de Películas") +
  theme_minimal()
```

```
# Mostrar gráficos
print(grafico_dispersion)
```


```
## `geom_smooth()` using formula = 'y ~ x'
```

¿Los altos presupuestos significan altos ingresos?


Correlación de Pearson: 0.78



```
print(hist_presupuesto)
```

```
print(hist_ingresos)
```




El análisis estadístico arroja un coeficiente de correlación de Pearson de 0.78, lo que confirma una relación positiva fuerte entre el presupuesto y los ingresos. Como se visualiza en el diagrama de dispersión, existe una tendencia clara donde una mayor inversión suele traducirse en mayores ganancias; sin embargo, la dispersión de los puntos indica que el éxito no está garantizado, existiendo películas de alto costo con retornos inferiores a lo esperado. Por su parte, los histogramas revelan que ambas variables presentan una distribución extremadamente sesgada a la derecha (no normal), lo que demuestra que la industria cinematográfica se compone mayoritariamente de producciones de bajo y mediano presupuesto, siendo las “superproducciones” multimillonarias casos excepcionales y atípicos dentro del conjunto de datos.

Ejercicio 4.12 - ¿Se asocian ciertos meses de lanzamiento con mejores ingresos?

```
movies <- movies %>%
  mutate(
    releaseDate = as.Date(releaseDate),
    releaseMonth = format(releaseDate, "%m")
  )

movies %>%
  filter(!is.na(releaseMonth), !is.na(revenue)) %>%
  group_by(releaseMonth) %>%
  summarise(ingreso_promedio = mean(revenue, na.rm = TRUE)) %>%
  ggplot(aes(x = releaseMonth, y = ingreso_promedio)) +
  geom_col(fill = "purple") +
```

```
labs(
  title = "Ingreso promedio por mes de estreno",
  x = "Mes",
  y = "Ingreso promedio"
)
```



Como se puede observar, los meses de mayo y junio concentran mayores ingresos promedio, lo cual sugiere que el momento del estreno influye en el desempeño financiero de las películas al ser épocas donde las personas obtienen mucho tiempo libre tales como las vacaciones de medio año para colegios.

Ejercicio 4.13 - ¿En qué meses se han visto los lanzamientos con mejores ingresos?

¿cuántas películas, en promedio, se han lanzado por mes?

```
movies %>%
  filter(!is.na(releaseMonth)) %>%
  group_by(releaseMonth) %>%
  summarise(
    peliculas = n(),
    ingreso_promedio = mean(revenue, na.rm = TRUE)
  ) %>%
  arrange(desc(ingreso_promedio))
```

```
## # A tibble: 12 x 3
##   releaseMonth películas ingreso_promedio
##   <chr>          <int>          <dbl>
## 1 06              819          94747108.
## 2 05              699          87719769.
## 3 07              812          76028696.
## 4 04              695          52671273.
## 5 03              816          51053300.
## 6 02              774          39138627.
## 7 10             1064          39133157.
## 8 08              914          35930725.
## 9 09             1078          31958536.
## 10 12             4361          16517826.
## 11 11             4730          12700099.
## 12 01             3119           7127284.
```

Al igual que en el inciso 4.12, Junio coincide como el mes con mayor demanda cinematográfica.

Ejercicio 4.14 - ¿Cómo se correlacionan las calificaciones con el éxito comercial?

```
# Correlacion numerica para ver si van de la mano o no
cor_calif_ingreso <- cor(movies$voteAvg, movies$revenue, use = "complete.obs")
print(paste("Coeficiente de correlación:", round(cor_calif_ingreso, 4)))
```


```
## [1] "Coeficiente de correlación: 0.2303"
```

```
# Grafico de dispersion
grafico_exit_comercial <- ggplot(movies, aes(x = voteAvg, y = revenue)) +
  geom_point(alpha = 0.3, color = "#8A2BE2") +
  geom_smooth(method = "lm", color = "black", se = FALSE) +
  labs(title = "¿Las películas con mejor calificación ganan más dinero?",
       subtitle = paste("Correlación de Pearson:", round(cor_calif_ingreso, 2)),
       x = "Calificación Promedio (0-10)",
       y = "Ingresos ($)") +
  theme_minimal()
print(grafico_exit_comercial)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

¿Las películas con mejor calificación ganan más dinero?

Correlación de Pearson: 0.23



El cálculo del coeficiente de correlación de Pearson arroja un valor de 0.23, lo cual evidencia una relación positiva débil entre la calidad percibida (calificación promedio) y el éxito comercial. Al observar el diagrama de dispersión, la nube de puntos no sigue un patrón lineal definido, sino que muestra una gran dispersión: existen numerosas películas con calificaciones excelentes (superiores a 8.0) que obtuvieron ingresos modestos, mientras que producciones con calificaciones promedio (entre 6.0 y 7.0) alcanzaron recaudaciones multimillonarias. Esto concluye que la valoración crítica de la audiencia no es un predictor fiable de la taquilla, y que el éxito financiero depende mayoritariamente de otros factores como el marketing, el presupuesto o la pertenencia a franquicias populares, más que de la “calidad” cinematográfica en sí misma.

Ejercicio 4.15 - ¿Qué estrategias de marketing, como videos promocionales o páginas

oficiales, generan mejores resultados?

```
movies <- movies |>
  mutate(
    tiene_homepage = ifelse(is.na(homePage) | homePage == "", "No", "Sí")
  )

movies |>
  filter(!is.na(video)) |>
  group_by(video, tiene_homepage) |>
  summarise(
    ingreso_promedio = mean(revenue, na.rm = TRUE),
```

```

    popularidad_promedio = mean(popularity, na.rm = TRUE),
    peliculas = n(),
    .groups = "drop"
)

```

```

## # A tibble: 4 x 5
##   video tiene_homepage ingreso_promedio popularidad_promedio peliculas
##   <lg1> <chr>          <dbl>          <dbl>          <int>
## 1 FALSE No           12508277.         14.1          14048
## 2 FALSE Sí           57762297.         50.3          5265
## 3 TRUE  No           423701.          39.0           60
## 4 TRUE  Sí           712829.          60.6           24

```

Podemos concluir que la existencia de una página oficial se asocia con mayores ingresos y niveles de popularidad. Asimismo, las películas que combinan video promocional y página oficial presentan la mayor popularidad promedio. Aunque algunos grupos presentan un número reducido de observaciones, la tendencia general sugiere que una estrategia de marketing digital más completa genera mejores resultados.

Ejercicio 4.16 - ¿La popularidad del elenco está directamente relacionada con el éxito

de taquilla?

```

# Coeficiente de correlacion
cor_actores <- cor(movies$actorsPopularity, movies$revenue, use = "complete.obs")
print(paste("Coeficiente de correlación:", round(cor_actores, 4)))

```

```
## [1] "Coeficiente de correlación: 0.0549"
```

```

# Grafico de dispersion
grafico_elenco_exit <- ggplot(movies, aes(x = actorsPopularity, y = revenue)) +
  geom_point(alpha = 0.4, color = "#FF8C00") + # Color Naranja (Dark Orange)
  geom_smooth(method = "lm", color = "blue", se = FALSE) + # Línea de tendencia azul
  labs(title = "¿Los actores famosos garantizan taquilla?",
       subtitle = paste("Correlación de Pearson:", round(cor_actores, 2)),
       x = "Popularidad del Elenco",
       y = "Ingresos ($)") +
  theme_minimal()

print(grafico_elenco_exit)

```


```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 18799 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```

```
## Warning: Removed 18799 rows containing missing values or values outside the scale range
## (`geom_point()`).
```

¿Los actores famosos garantizan taquilla?

Correlación de Pearson: 0.05



El análisis estadístico arroja un coeficiente de correlación de Pearson de 0.05, lo cual indica una correlación nula. Contrario a la creencia popular de que el “Star Power” impulsa la taquilla, los datos de esta muestra revelan que no existe ninguna relación lineal entre la popularidad del elenco y los ingresos generados. Como se observa en el gráfico, la línea de tendencia es completamente plana (horizontal), demostrando que películas con actores de alta popularidad no recaudaron necesariamente más que aquellas con elencos desconocidos. Esto sugiere que, al menos en este conjunto de datos depurado, la fama de los actores es irrelevante para predecir el éxito financiero.